Universidad de Antioquia
Facultad de Ciencias Exactas y Naturales
Instituto de Matemáticas

SEMINARIO DE SERIES DE TIEMPO I

Juan Camilo Melo Ortíz – Santiago Duque Pérez

Profesor: Duván Cataño
Semestre 2026-2

1. **TÍTULO**
   Más allá de ARMA y ARIMA: modelos ARFIMA para series con memoria larga

2. **RESUMEN**
   Los modelos ARMA y ARIMA vistos en el curso obligan a escoger entre dos extremos: series con memoria corta, en las que los choques desaparecen rápido ($d = 0$), o series con raíz unitaria, en las que los choques son permanentes ($d = 1$). En este trabajo estudiamos los modelos ARFIMA, que permiten que el orden de diferenciación d tome valores fraccionarios y así describen series con memoria larga, cuyas autocorrelaciones decaen de forma muy lenta. Presentamos el operador de diferenciación fraccional, las propiedades del modelo y dos métodos para estimar d: el estimador semiparamétrico de Geweke y Porter-Hudak y la máxima verosimilitud. Como aplicación usamos los niveles mínimos anuales del río Nilo entre los años 622 y 1284, la serie con la que Hurst descubrió la memoria larga. Encontramos que las pruebas ADF y KPSS rechazan al mismo tiempo, que el modelo escogido es un ARFIMA$(0, d, 0)$ con $\hat{d} = 0.393$ (exponente de Hurst de 0.89) y que, con un solo parámetro, este modelo ajusta la serie tan bien como un ARMA$(2, 1)$ y pronostica mejor que el ARMA y el ARIMA comparados. Concluimos que los modelos ARFIMA son una extensión útil de los modelos del curso para series con dependencia persistente, aunque su estimación es más delicada y su ventaja en el pronóstico se reduce a horizontes muy largos.

3. **PALABRAS CLAVES**
   Memoria larga, diferenciación fraccional, modelos ARFIMA, exponente de Hurst, estimador de Geweke y Porter-Hudak, río Nilo.

4. **INTRODUCCIÓN**

   En el curso de Series de Tiempo trabajamos con dos grandes familias de modelos. Los modelos ARMA describen series estacionarias en las que el efecto de un choque desaparece rápido, y su función de autocorrelación cae a cero de forma exponencial. Los modelos ARIMA, en cambio, describen series con una raíz unitaria, en las que los choques tienen un efecto permanente y la serie hay que diferenciarla una vez antes de modelarla. En la práctica, la decisión de diferenciar o no una serie se toma casi siempre entre esas dos opciones: $d = 0$ o $d = 1$.

   Sin embargo, hay series que no encajan bien en ninguno de los dos casos. Son series estacionarias, pero en las que lo que pasó hace mucho tiempo sigue influyendo en el presente: sus autocorrelaciones no son muy grandes, pero bajan tan despacio que siguen siendo importantes después de decenas de rezagos. A este fenómeno se le conoce como *memoria larga*, y fue descrito por primera vez por el hidrólogo H. E. Hurst al estudiar los caudales del río Nilo. Para estas series, un ARMA se queda corto y un ARIMA se pasa.

   Los modelos ARFIMA, propuestos de forma independiente por Granger y Joyeux (1980) y por Hosking (1981), resuelven este problema permitiendo que el orden de diferenciación d tome valores fraccionarios. Así, en lugar de escoger entre no diferenciar y diferenciar una vez, el modelo estima un valor intermedio que mide directamente la intensidad de la memoria de la serie.

   En este trabajo presentamos los modelos ARFIMA como una extensión natural de los ARMA y ARIMA vistos en el curso. Primero revisamos la teoría: el concepto de memoria larga, el operador de diferenciación fraccional, las propiedades del modelo y dos métodos para estimar d, uno

semiparamétrico y otro por máxima verosimilitud. Después ilustramos todo con la misma serie que dio origen a esta teoría: los niveles mínimos anuales del río Nilo entre los años 622 y 1284. Sobre esa serie ajustamos un modelo ARFIMA y lo comparamos, paso a paso, con el mejor ARMA y el mejor ARIMA, tanto en su ajuste como en su capacidad de pronóstico. Todo el análisis se hizo en R y se puede reproducir con el código disponible en el repositorio del proyecto (`https://github.com/camilomelo928/Series-de-Tiempo`).

El documento está organizado así: en la sección 5 se presenta el marco teórico, en las secciones 6 y 7 los objetivos y la metodología, en la sección 8 la aplicación a la serie del Nilo y en la sección 9 las conclusiones, donde se confrontan los resultados con la teoría y se discuten las ventajas y desventajas del modelo.

5. MARCO TEÓRICO

5.1 Memoria corta y memoria larga

En el curso trabajamos principalmente con dos familias de modelos. La primera son los procesos ARMA(p, q), que son estacionarios y cuya función de autocorrelación (ACF) decae a cero de forma exponencial. Es decir, existen constantes $C > 0$ y $0 < r < 1$ tales que

$$|\rho(h)| \leq C\, r^h, \qquad h = 1, 2, \ldots \tag{1}$$

Esto quiere decir que un choque que ocurre hoy deja de influir en la serie después de pocos períodos. Por esa razón se dice que los ARMA tienen *memoria corta*. La segunda familia son los ARIMA$(p, 1, q)$, en los que la serie tiene una raíz unitaria y un choque nunca se olvida: su efecto es permanente.

Sin embargo, en la práctica aparecen series que no encajan en ninguno de los dos casos. Su ACF muestral no tiene valores muy grandes, pero baja muy despacio y se mantiene positiva durante muchísimos rezagos. Como discuten Granger y Joyeux (1980), para este tipo de series ni diferenciar ni dejar de diferenciar resulta del todo adecuado: si no se diferencia, queda una dependencia que el ARMA no logra capturar, y si se diferencia una vez, se eliminan componentes de baja frecuencia que sí eran importantes (lo que se conoce como sobrediferenciación).

Decimos que un proceso estacionario $\{x_t\}$ tiene *memoria larga* cuando sus autocorrelaciones decaen de forma hiperbólica, es decir, como una potencia de h y no como una exponencial:

$$\rho(h) \sim C\, h^{2d-1}, \qquad h \to \infty, \qquad 0 < d < \tfrac{1}{2}, \tag{2}$$

donde C es una constante y d es el llamado *parámetro de memoria*. Una consecuencia de esto es que la suma de las autocorrelaciones no converge, $\sum_h |\rho(h)| = \infty$, algo que nunca pasa en un ARMA. Visto en el dominio de las frecuencias, la memoria larga equivale a que la densidad espectral $f(\lambda)$ se dispara en el origen:

$$f(\lambda) \sim C_f\, \lambda^{-2d}, \qquad \lambda \to 0^+. \tag{3}$$

En otras palabras, la serie tiene una cantidad muy grande de variabilidad asociada a ciclos de período muy largo (Shumway y Stoffer, 2017).

5.2 Un poco de historia: Hurst y el río Nilo

El fenómeno de la memoria larga se documentó por primera vez en hidrología. El ingeniero británico H. E. Hurst, que trabajó durante décadas en el diseño de represas sobre el río Nilo, estudió cómo crece el rango ajustado de los caudales acumulados (el estadístico R/S) a medida que aumenta el tamaño n de la muestra. Si los caudales de un año a otro fueran independientes, ese rango debería crecer aproximadamente como $n^{0.5}$. Sin embargo, Hurst encontró que en el Nilo, y en muchas otras series naturales, crecía como n^H con H claramente mayor que 0.5, alrededor de 0.7 en promedio (Hurst, 1951). Esto indicaba que los años secos tendían a venir seguidos de más años secos, y los húmedos de más años húmedos, durante períodos mucho más largos de lo que un modelo de memoria corta puede explicar. A este comportamiento se le conoce como *efecto Hurst*, y el valor H como *exponente de Hurst*. Como veremos más adelante, este exponente se relaciona directamente con el parámetro d de los modelos ARFIMA.

5.3 El operador de diferenciación fraccional

La idea central de Granger y Joyeux (1980) y de Hosking (1981) fue permitir que el orden de diferenciación d del modelo ARIMA tome valores no enteros. El problema es darle sentido a una

expresión como $(1-B)^{0.3}$, donde B es el operador de rezago ($Bx_t = x_{t-1}$). Para esto se usa la expansión binomial, que es válida para cualquier número real d:

$$(1-B)^d = \sum_{j=0}^{\infty} \binom{d}{j} (-B)^j = 1 - dB - \frac{d(1-d)}{2!}B^2 - \frac{d(1-d)(2-d)}{3!}B^3 - \cdots \tag{4}$$

Escrito de forma compacta, $(1-B)^d = \sum_{j=0}^{\infty} \pi_j B^j$, donde los coeficientes se pueden expresar con la función gamma o calcular de forma recursiva:

$$\pi_j = \frac{\Gamma(j-d)}{\Gamma(j+1)\,\Gamma(-d)}, \qquad \pi_0 = 1, \qquad \pi_j = \pi_{j-1}\,\frac{j-1-d}{j}. \tag{5}$$

Cuando d es un entero positivo, la suma se corta y recuperamos las diferencias usuales. Por ejemplo, con $d = 1$ obtenemos $1 - B$. Pero cuando d no es entero, la suma es infinita: la serie diferenciada $(1-B)^d x_t = \sum_j \pi_j x_{t-j}$ depende de *todo* el pasado de la serie, con pesos que decaen lentamente, del orden de $\pi_j \sim j^{-d-1}/\Gamma(-d)$. Esa es precisamente la forma en que el modelo incorpora la memoria larga. Se puede pensar entonces la diferenciación fraccional como un punto intermedio entre no diferenciar ($d = 0$) y diferenciar una vez ($d = 1$).

5.4 El ruido fraccional: ARFIMA$(0, d, 0)$

El caso más sencillo, que ayuda a entender todo lo demás, es el ruido blanco fraccionalmente integrado:

$$(1-B)^d x_t = w_t, \qquad w_t \sim RB(0, \sigma_w^2). \tag{6}$$

Hosking (1981) mostró que este proceso es estacionario si $d < \frac{1}{2}$ e invertible si $d > -\frac{1}{2}$. En ese rango tiene una representación de media móvil infinita,

$$x_t = (1-B)^{-d} w_t = \sum_{j=0}^{\infty} \psi_j w_{t-j}, \qquad \psi_j = \frac{\Gamma(j+d)}{\Gamma(j+1)\,\Gamma(d)} \sim \frac{j^{d-1}}{\Gamma(d)}, \tag{7}$$

y sus principales propiedades se pueden escribir de forma explícita. Su varianza es

$$\gamma(0) = \sigma_w^2\,\frac{\Gamma(1-2d)}{\Gamma^2(1-d)}, \tag{8}$$

y su ACF es

$$\rho(h) = \frac{\Gamma(h+d)\,\Gamma(1-d)}{\Gamma(h-d+1)\,\Gamma(d)} = \prod_{k=1}^{h} \frac{k-1+d}{k-d}, \qquad h = 1, 2, \ldots \tag{9}$$

En particular, $\rho(1) = d/(1-d)$ y, para rezagos grandes, $\rho(h) \sim \frac{\Gamma(1-d)}{\Gamma(d)}\,h^{2d-1}$, que es justo el decaimiento hiperbólico de la ecuación (2). La función de autocorrelación parcial (PACF) también tiene una forma sencilla, $\phi_{hh} = d/(h-d)$, y decae lentamente en lugar de cortarse como pasaría en un AR. Por último, la densidad espectral es

$$f(\lambda) = \frac{\sigma_w^2}{2\pi}\,\left|1 - e^{-i\lambda}\right|^{-2d} = \frac{\sigma_w^2}{2\pi}\,\left[2\sin(\lambda/2)\right]^{-2d}, \qquad -\pi \le \lambda \le \pi, \tag{10}$$

que para λ cerca de cero se comporta como λ^{-2d}, de acuerdo con la ecuación (3).

5.5 El modelo ARFIMA(p, d, q)

El ruido fraccional solo tiene un parámetro, así que no permite describir al mismo tiempo la dependencia de corto y de largo plazo. Para eso se combina con una parte ARMA, y se obtiene el modelo autorregresivo fraccionalmente integrado de medias móviles, ARFIMA(p, d, q):

$$\phi(B)\,(1-B)^d\,(x_t - \mu) = \theta(B)\,w_t, \qquad w_t \sim RB(0, \sigma_w^2), \tag{11}$$

donde $\phi(B) = 1 - \phi_1 B - \cdots - \phi_p B^p$ y $\theta(B) = 1 + \theta_1 B + \cdots + \theta_q B^q$ son los mismos polinomios que usamos en los modelos ARMA. Si las raíces de $\phi(z)$ y de $\theta(z)$ están fuera del círculo unitario y $-\frac{1}{2} < d < \frac{1}{2}$, el proceso es estacionario e invertible (Hosking, 1981).

La gracia del modelo está en la división del trabajo entre sus partes. El parámetro d se encarga del comportamiento de largo plazo, es decir, de la cola de la ACF y del espectro en frecuencias bajas, mientras que los parámetros ϕ y θ se encargan de la estructura en los primeros rezagos. Esto se ve claramente en su densidad espectral:

$$f(\lambda) = \frac{\sigma_w^2}{2\pi}\,\frac{|\theta(e^{-i\lambda})|^2}{|\phi(e^{-i\lambda})|^2}\,\left|1 - e^{-i\lambda}\right|^{-2d}, \tag{12}$$

que es el espectro de un ARMA multiplicado por el factor fraccional. Hosking (1981) destaca justamente esta flexibilidad para modelar a la vez el comportamiento de corto y de largo plazo como la principal ventaja frente a otros modelos de persistencia que existían en ese momento.

El valor de d resume el tipo de memoria de la serie, como se muestra en la Tabla 1.

Valor de d	**Comportamiento del proceso**
$-\frac{1}{2} < d < 0$	Estacionario con antipersistencia (memoria intermedia)
$d = 0$	ARMA usual, memoria corta
$0 < d < \frac{1}{2}$	Estacionario con memoria larga
$\frac{1}{2} \leq d < 1$	No estacionario, pero con reversión a la media
$d = 1$	Raíz unitaria, ARIMA$(p, 1, q)$

Tabla 1: Interpretación del parámetro de diferenciación fraccional d.

Cuando $d \geq \frac{1}{2}$, lo usual es diferenciar la serie una vez y modelar ∇x_t como un ARFIMA con parámetro $d - 1$, que ya queda en el rango estacionario.

Finalmente, el parámetro de memoria está ligado al exponente de Hurst de la sección 5.2 por la relación

$$H = d + \tfrac{1}{2}. \tag{13}$$

Así, un H cercano a 0.7, como el que encontró Hurst en promedio para muchas series naturales, corresponde a un d cercano a 0.2, es decir, a una serie estacionaria con memoria larga.

5.6 Estimación del parámetro d

En la literatura hay muchos métodos para estimar d. En este trabajo nos concentramos en dos, que representan los dos enfoques principales.

Estimador semiparamétrico de Geweke y Porter-Hudak (GPH). Geweke y Porter-Hudak (1983) aprovechan que, cerca del origen, el espectro de un ARFIMA se comporta como $[2\sin(\lambda/2)]^{-2d}$ multiplicado por un factor que es aproximadamente constante. Tomando logaritmos y reemplazando el espectro por el periodograma $I(\lambda_j)$, se llega a la regresión

$$\log I(\lambda_j) = c - d \log\big[4\sin^2(\lambda_j/2)\big] + e_j, \qquad j = 1, \ldots, m, \tag{14}$$

donde $\lambda_j = 2\pi j/n$ son las frecuencias de Fourier. El estimador $\hat{d}_{GPH}$ es simplemente la pendiente estimada por mínimos cuadrados ordinarios (con el signo cambiado). La clave está en usar solo las m frecuencias más bajas, que son las que contienen la información sobre la memoria larga. Los autores sugirieron $m = \sqrt{n}$, y bajo ciertas condiciones el estimador es consistente y asintóticamente normal, con varianza aproximada $\pi^2/(24m)$. Su gran ventaja es que no necesita especificar los órdenes p y q de la parte ARMA, por eso se le llama semiparamétrico. Su desventaja es que depende bastante de la elección de m y tiene una varianza relativamente grande.

Máxima verosimilitud. El segundo enfoque estima todos los parámetros del modelo $(d, \phi_1, \ldots, \phi_p, \theta_1, \ldots, \theta_q, \sigma_w^2)$ al mismo tiempo, suponiendo que la serie es gaussiana. Calcular la verosimilitud exacta es costoso, porque la memoria larga hace que la matriz de covarianzas de las n observaciones no tenga la estructura simple que tiene un ARMA. Haslett y Raftery (1989) propusieron una aproximación rápida a esta verosimilitud que es la que implementa el paquete `fracdiff` de R (Maechler et al., 2026). A diferencia de GPH, este método sí requiere fijar p y q, pero a cambio es más eficiente y permite comparar modelos con criterios de información como el AIC y el BIC, igual que con los ARIMA vistos en clase.

5.7 Pronóstico

Como el ARFIMA es invertible, se puede escribir como un AR(∞), $x_t = \sum_{j\geq 1} \varphi_j x_{t-j} + w_t$, y el mejor predictor lineal de x_{n+h} se construye a partir de esa representación, truncada en el número de datos disponibles. La diferencia con un ARMA está en cómo se comportan los pronósticos a medida que crece el horizonte h. En un ARMA, los pronósticos regresan a la media muy rápido, de forma exponencial. En un ARFIMA con $0 < d < \frac{1}{2}$ también regresan a la media, pero de forma lenta, porque el modelo "recuerda" lo que pasó hace mucho tiempo. Geweke y Porter-Hudak (1983) encontraron que, en varias series económicas, este tipo de modelos daba pronósticos fuera de muestra más confiables que los procedimientos convencionales, y esa es una de las motivaciones prácticas más fuertes para usarlos.

6. OBJETIVOS

Objetivo general

Estudiar los modelos ARFIMA como una extensión de los modelos ARMA y ARIMA vistos en el curso, que permite describir series de tiempo con memoria larga, e ilustrar su uso con la serie histórica de los niveles mínimos anuales del río Nilo.

Objetivos específicos

- Describir el concepto de memoria larga y diferenciarlo de la memoria corta de los modelos ARMA y de la raíz unitaria de los modelos ARIMA.
- Presentar el operador de diferenciación fraccional, las principales propiedades del modelo ARFIMA(p, d, q) y la interpretación del parámetro d.
- Estimar el parámetro de memoria d de la serie del Nilo mediante el estimador de Geweke y Porter-Hudak y mediante máxima verosimilitud.
- Comparar el ajuste y la capacidad de pronóstico del modelo ARFIMA frente a modelos ARMA y ARIMA ajustados a la misma serie.

7. METODOLOGÍA

El trabajo tiene un carácter descriptivo y aplicado. Primero se hace una revisión teórica de los modelos ARFIMA a partir de las referencias bibliográficas, y luego se ilustran sus propiedades con un conjunto de datos reales. Como el objetivo es mostrar qué aporta este modelo frente a lo visto en el curso, en cada etapa del análisis se compara el ARFIMA con un modelo ARMA (que supone memoria corta) y con un modelo ARIMA con $d = 1$ (que supone raíz unitaria).

Datos. Se usa la serie de los niveles mínimos anuales del río Nilo entre los años 622 y 1284, medidos en el nilómetro de Roda, cerca de El Cairo (Toussoun, 1925). Son 663 observaciones y están disponibles en el paquete `longmemo` de R con el nombre `NileMin`.

Etapas del análisis.

1. *Exploración de la serie.* Se grafica la serie y se calculan su ACF y su PACF muestrales. Lo que se busca es la señal típica de la memoria larga: autocorrelaciones que no son muy grandes pero que decaen muy despacio, a diferencia del decaimiento rápido de un ARMA.

2. *Pruebas de estacionariedad.* Se aplican la prueba de Dickey-Fuller aumentada (ADF), cuya hipótesis nula es la existencia de una raíz unitaria, y la prueba KPSS, cuya hipótesis nula es la estacionariedad. Si la ADF rechaza la raíz unitaria y al mismo tiempo la KPSS rechaza la estacionariedad, la serie no se comporta ni como un ARMA ni como un ARIMA, lo cual es un indicio de memoria larga.
3. *Estimación de d.* Se estima el parámetro de memoria con el estimador semiparamétrico de Geweke y Porter-Hudak (1983), probando varios valores de m, y por máxima verosimilitud siguiendo a Haslett y Raftery (1989). Para el segundo método se ajustan modelos ARFIMA(p, d, q) con $p, q \in \{0, 1, 2\}$ y se escoge el de menor BIC, por ser el criterio que favorece modelos más parsimoniosos.
4. *Modelos de comparación.* Sobre la misma serie se ajustan el mejor modelo ARMA(p, q) y el mejor ARIMA$(p, 1, q)$, seleccionados también por AIC y BIC.
5. *Diagnóstico.* Para cada modelo se revisan los residuales con su ACF y con la prueba de Ljung-Box, para verificar que se comporten como ruido blanco.
6. *Pronóstico y comparación.* Se separan las últimas 50 observaciones como conjunto de prueba y se estiman los tres modelos con las restantes. Se evalúan dos tipos de pronóstico: a varios pasos (los 50 años desde el final del entrenamiento) y a un paso (cada año con la información hasta el año anterior). Los errores se comparan con la raíz del error cuadrático medio (RMSE) y el error absoluto medio (MAE), usando como referencia el pronóstico con la media de la serie.

Herramientas. Todo el análisis se hace en R. Se usa el paquete `fracdiff` (Maechler et al., 2026) para estimar los modelos ARFIMA y el estimador GPH, `forecast` para los modelos ARMA y ARIMA y para los pronósticos, `tseries` para las pruebas ADF y KPSS, y `longmemo` para obtener los datos.

8. APLICACIÓN

8.1 Los datos

Trabajamos con los niveles mínimos anuales del río Nilo medidos en el nilómetro de Roda, cerca de El Cairo, entre los años 622 y 1284 (Toussoun, 1925). Son $n = 663$ observaciones anuales, con un nivel mínimo de 935, un máximo de 1466 y una media de 1148. La Figura 1 muestra la serie. No se ve tendencia ni estacionalidad, pero sí algo muy llamativo: la serie pasa *rachas largas* por encima o por debajo de la media. Por ejemplo, entre los años 750 y 800 casi todos los valores están por debajo de la media, y entre 1100 y 1150 casi todos están por encima. Ese comportamiento es justamente el efecto Hurst del que hablamos en la sección 5.2.

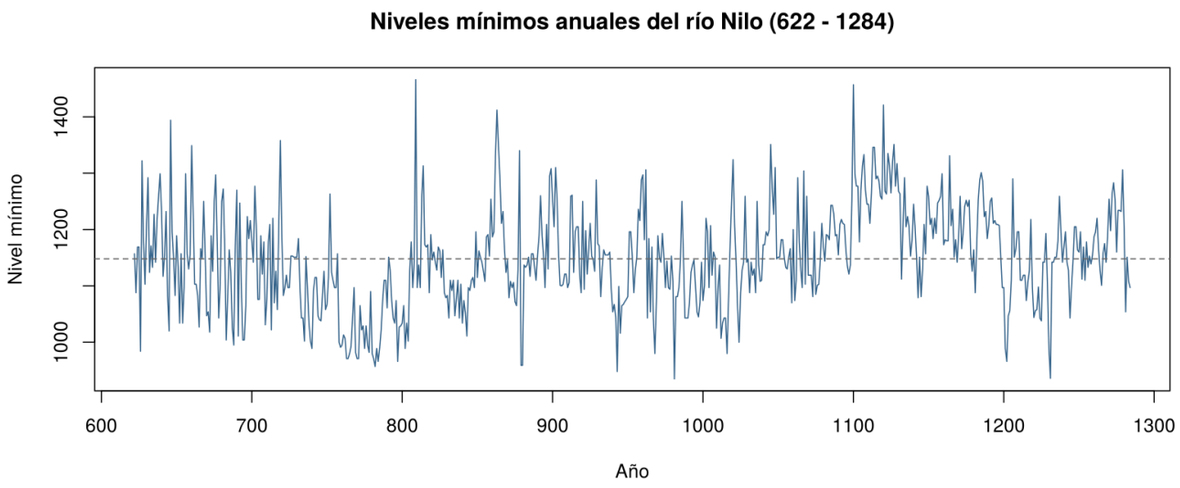


Figura 1: Niveles mínimos anuales del río Nilo, 622 a 1284. La línea punteada es la media de la serie.

8.2 Exploración: ACF y PACF muestrales

La Figura 2 muestra la ACF y la PACF muestrales hasta el rezago 100. La ACF es la señal más clara de memoria larga que tiene la serie. Su primer valor es $\hat{\rho}(1) = 0.575$, que no es muy grande (en una

serie con raíz unitaria estaría muy cerca de 1), pero después baja muchísimo más despacio de lo que bajaría en un ARMA: en el rezago 10 todavía vale 0.278, en el rezago 20 vale 0.232 y en el rezago 50 vale 0.135. Las autocorrelaciones siguen por fuera de la banda de significancia ($\pm 1.96/\sqrt{n} = \pm 0.076$) hasta cerca del rezago 75, es decir, la serie parece "recordar" lo que pasó hace más de 70 años. La PACF, en cambio, tiene unos pocos valores significativos en los primeros rezagos y después se queda dentro de la banda.

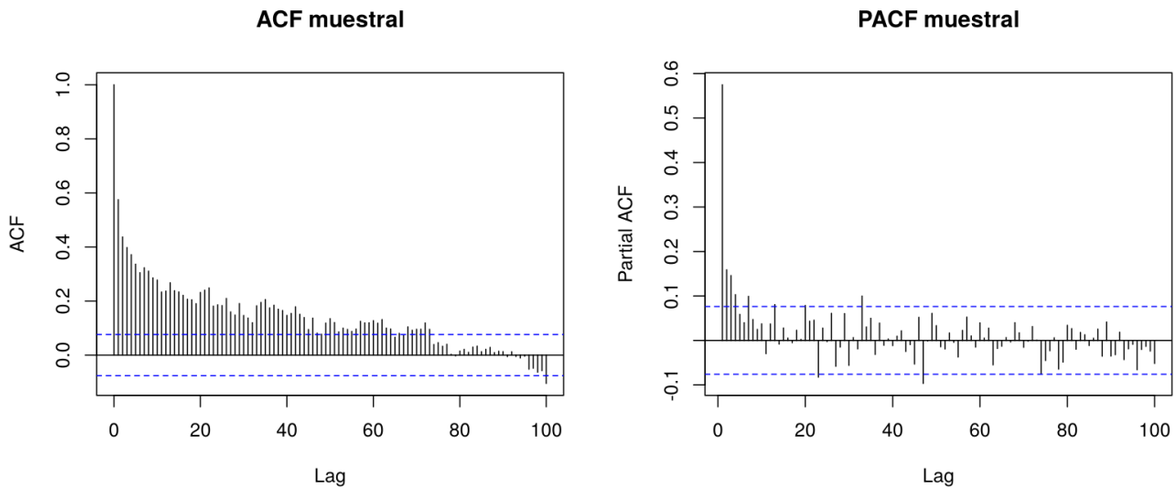


Figura 2: ACF y PACF muestrales de la serie del Nilo hasta el rezago 100.

8.3 Pruebas de estacionariedad

La Tabla 2 resume las pruebas ADF y KPSS. Las dos rechazan su hipótesis nula con un p-valor menor a 0.01, lo que a primera vista parece una contradicción: la ADF dice que la serie *no* tiene raíz unitaria y la KPSS dice que la serie *no* es estacionaria. En realidad no hay contradicción, sino que ninguno de los dos modelos que comparan estas pruebas describe bien la serie. La serie es demasiado persistente para ser un ARMA de memoria corta, y no lo suficiente para tener una raíz unitaria. Este resultado es un indicio clásico de memoria larga y es la primera justificación para usar un ARFIMA.

Prueba	**Estadístico**	**p-valor**	**Conclusión**
ADF (H_0: raíz unitaria)	-5.03	< 0.01	Se rechaza: no hay raíz unitaria
KPSS (H_0: estacionariedad)	1.72	< 0.01	Se rechaza: no es estacionaria

Tabla 2: Pruebas de estacionariedad para la serie del Nilo.

8.4 Estimación del parámetro de memoria d

Estimador GPH. La Tabla 3 muestra el estimador de Geweke y Porter-Hudak (1983) con tres anchos de banda $m = n^{\alpha}$. Con la propuesta original de los autores, $\alpha = 0.5$, se usan solo $m = 25$ frecuencias y se obtiene $\hat{d} = 0.504$. Al usar más frecuencias, el estimador cambia bastante y llega a 0.396 con $m = 94$. Esto confirma lo que dijimos en la sección 5.6: el GPH es muy sensible a la elección de m y tiene errores estándar grandes. Aun así, en los tres casos el valor estimado está lejos de cero, lo que apoya la presencia de memoria larga.

α	$m = n^{\alpha}$	$\hat{d}_{GPH}$	Error estándar asintótico
0.5	25	0.504	0.157
0.6	49	0.537	0.105
0.7	94	0.396	0.072

Tabla 3: Estimador GPH de d para distintos anchos de banda.

Máxima verosimilitud. Ajustamos los nueve modelos ARFIMA(p, d, q) con $p, q \in \{0, 1, 2\}$ usando el paquete `fracdiff`. La Tabla 4 muestra los mejores según el BIC. En todos los modelos el valor estimado de d está entre 0.35 y 0.39, así que la estimación de la memoria es bastante estable sin importar la parte ARMA que se agregue. El modelo con menor BIC es el ARFIMA$(0, d, 0)$, es

decir, el ruido fraccional, que tiene *un solo parámetro*. El ARFIMA$(2, d, 2)$ tiene el menor AIC, pero al revisar sus coeficientes encontramos que las raíces del polinomio AR y las del polinomio MA prácticamente coinciden, así que las dos partes se cancelan entre sí y el modelo está sobreajustado. Por eso escogemos el ARFIMA$(0, d, 0)$.

Modelo	$\hat{d}$	**log-verosimilitud**	**AIC**	**BIC**
ARFIMA$(0, d, 0)$	0.393	-3757.76	7519.52	**7528.52**
ARFIMA$(0, d, 1)$	0.353	-3758.06	7522.13	7535.62
ARFIMA$(1, d, 0)$	0.355	-3758.16	7522.31	7535.80
ARFIMA$(2, d, 2)$	0.384	-3751.00	**7514.00**	7540.98

Tabla 4: Mejores modelos ARFIMA(p, d, q) estimados por máxima verosimilitud, ordenados por BIC.

Para el modelo escogido obtenemos $\hat{d} = 0.393$, con un error estándar asintótico de $\sqrt{6/(\pi^2 n)} = 0.030$ y un intervalo de confianza del 95 % de $[0.334,\ 0.453]$. El intervalo queda completamente dentro de $(0, 0.5)$, así que, de acuerdo con la Tabla 1, la serie del Nilo es *estacionaria con memoria larga*: no necesita diferenciarse, pero tampoco es un ARMA. El exponente de Hurst correspondiente es $\hat{H} = \hat{d} + 0.5 = 0.89$, que está bastante por encima del valor de 0.5 que correspondería a una serie sin memoria larga.

8.5 Comparación con los modelos ARMA y ARIMA

Sobre la misma serie escogimos el mejor ARMA(p, q) y el mejor ARIMA$(p, 1, q)$ con la función `auto.arima`. Los resultados están en la Tabla 5.

Modelo	**Parámetros**	**log-verosimilitud**	**AIC**	**BIC**
ARFIMA$(0, d, 0)$	1	-3757.76	7519.52	7528.52
ARMA$(2, 1)$	3	-3756.37	7522.74	7545.23
ARIMA$(1, 1, 3)$	4	-3752.93	7515.86*	7538.33*

* Calculados sobre la serie diferenciada, no comparables con los otros dos modelos.

Tabla 5: Modelos ARFIMA, ARMA y ARIMA ajustados a la serie del Nilo. Los parámetros no incluyen la media ni la varianza.

Vale la pena anotar que estos dos modelos son exactamente los que propone `auto.arima` cuando lo dejamos escoger también el orden de diferenciación. Esta función decide d con una prueba de raíz unitaria: con la prueba KPSS, que es la que usa por defecto, escoge $d = 1$ y llega al ARIMA$(1, 1, 3)$; con la prueba ADF escoge $d = 0$ y llega al ARMA$(2, 1)$. Es decir, el modelo automático cambia por completo según la prueba que se use, porque solo puede escoger entre no diferenciar y diferenciar una vez. Esto muestra bien el problema que resuelve el ARFIMA: con una serie de memoria larga, la decisión entre $d = 0$ y $d = 1$ no tiene una respuesta correcta, y lo razonable es estimar un d intermedio.

Lo primero que llama la atención es la parsimonia. Para describir la serie, el ARMA necesita tres parámetros ($\phi_1 = 1.28$, $\phi_2 = -0.30$ y $\theta_1 = -0.85$), y aun así tiene un AIC y un BIC peores que los del ARFIMA$(0, d, 0)$, que usa uno solo. Además, el ARMA tiene una raíz autorregresiva muy cerca del círculo unitario, que es la forma en que un modelo de memoria corta intenta imitar una persistencia que en realidad es de largo plazo. El ARIMA, por su lado, no se puede comparar con los criterios de información, porque su verosimilitud se calcula sobre la serie diferenciada y no sobre la original. Por eso la comparación justa entre los tres es la de pronóstico (sección 8.7).

La Figura 3 compara los modelos en el dominio de las frecuencias, que es donde la diferencia entre memoria corta y larga se ve más clara. En escala logarítmica en ambos ejes, la densidad espectral del ARFIMA$(0, d, 0)$ es prácticamente una recta con pendiente $-2\hat{d}$, que sigue creciendo a medida que la frecuencia se acerca a cero, tal como dice la ecuación (3). El espectro del ARMA, en cambio, es acotado y tiene que aplanarse cerca del origen. En el rango de frecuencias que tiene la muestra los dos modelos se parecen bastante, pero la forma en la que lo logran es muy distinta: el ARFIMA lo hace con un solo parámetro que describe directamente la memoria, y el ARMA lo hace combinando tres parámetros para aproximar esa misma forma.

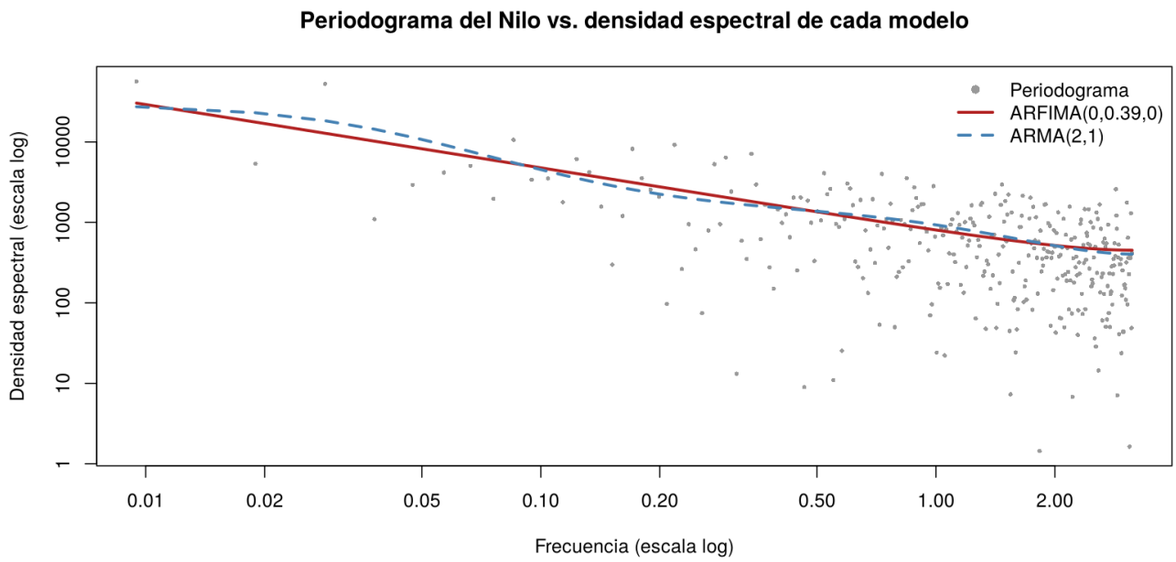


Figura 3: Periodograma de la serie del Nilo (puntos) y densidad espectral estimada de los modelos ARFIMA$(0, d, 0)$ y ARMA$(2, 1)$, en escala log-log.

8.6 Diagnóstico de los residuales

Para cada modelo aplicamos la prueba de Ljung-Box con 20 rezagos, cuya hipótesis nula es que los residuales son ruido blanco. Los p-valores fueron 0.866 para el ARFIMA$(0, d, 0)$, 0.838 para el ARMA$(2, 1)$ y 0.834 para el ARIMA$(1, 1, 3)$, así que en ningún caso se rechaza la hipótesis nula. La Figura 4 muestra los residuales del ARFIMA y su ACF, que se queda dentro de las bandas de significancia. Es decir, con un solo parámetro el ARFIMA logra capturar toda la dependencia de la serie, algo que el ARMA y el ARIMA consiguen solo con tres y cuatro parámetros.

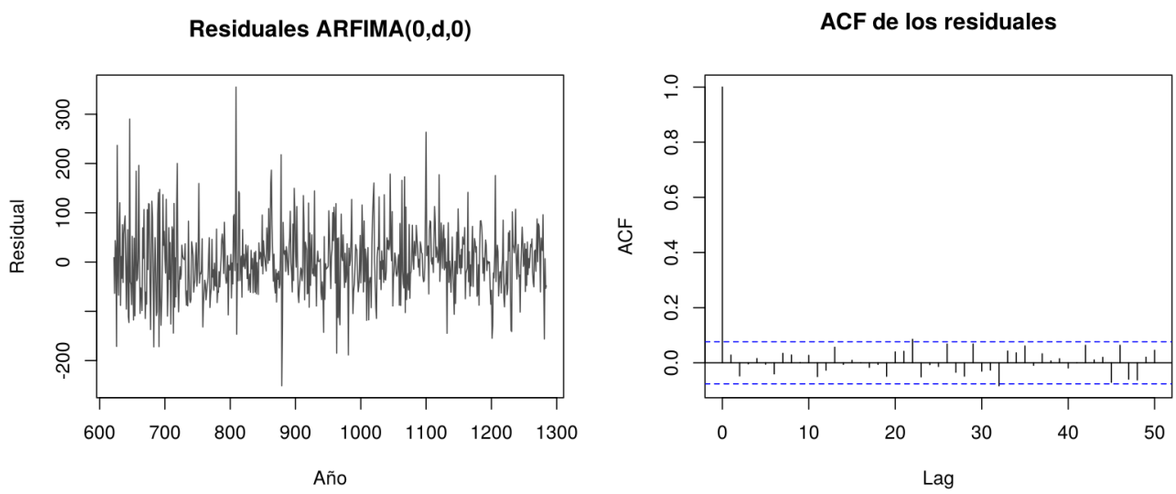


Figura 4: Residuales del modelo ARFIMA$(0, d, 0)$ y su ACF muestral.

8.7 Pronóstico fuera de muestra

Para comparar los tres modelos en igualdad de condiciones, separamos las últimas 50 observaciones (años 1235 a 1284) como conjunto de prueba y estimamos los modelos solo con las 613 observaciones anteriores. Como referencia usamos el pronóstico más sencillo posible: predecir todos los años con la media del entrenamiento. Los errores están en la Tabla 6.

	A un paso		A varios pasos (50 años)	
Modelo	RMSE	MAE	RMSE	MAE
ARFIMA$(0, d, 0)$	**50.10**	**39.85**	62.59	49.30
ARMA$(2, 1)$	50.79	40.71	68.90	55.99
ARIMA$(1, 1, 3)$	50.71	40.54	74.77	60.77
Media del entrenamiento	60.73	46.94	**60.73**	**46.94**

Tabla 6: Errores de pronóstico sobre las últimas 50 observaciones de la serie.

Pronóstico a un paso. Aquí cada año se pronostica con toda la información disponible hasta el año anterior. Los tres modelos le ganan claramente a la media, con una reducción del RMSE de alrededor del 17 %, lo que muestra que la dependencia de la serie sí sirve para predecir. El ARFIMA tiene el menor error de los tres, aunque la diferencia con el ARMA y el ARIMA es pequeña.

Pronóstico a varios pasos. Aquí se pronostican los 50 años de una vez, desde el final del entrenamiento. La Figura 5 muestra que las diferencias entre los modelos son más grandes. El ARIMA, que supone que los choques son permanentes, deja el pronóstico casi plano en un nivel bajo y es el que más se equivoca. El ARMA y el ARFIMA sí regresan hacia la media, pero el ARFIMA lo hace de forma más gradual, como corresponde a un proceso con memoria larga, y tiene un error claramente menor que el del ARMA. Sin embargo, a un horizonte tan largo ninguno de los tres modelos le gana a la media sola, que tiene el menor RMSE. Esto tiene sentido: cuando se pronostica muy lejos, cualquier modelo estacionario termina convergiendo a la media, así que la ventaja de modelar la dependencia se va perdiendo con el horizonte. Lo importante es que, de los tres modelos, el ARFIMA es el que menos se aleja de ese comportamiento.

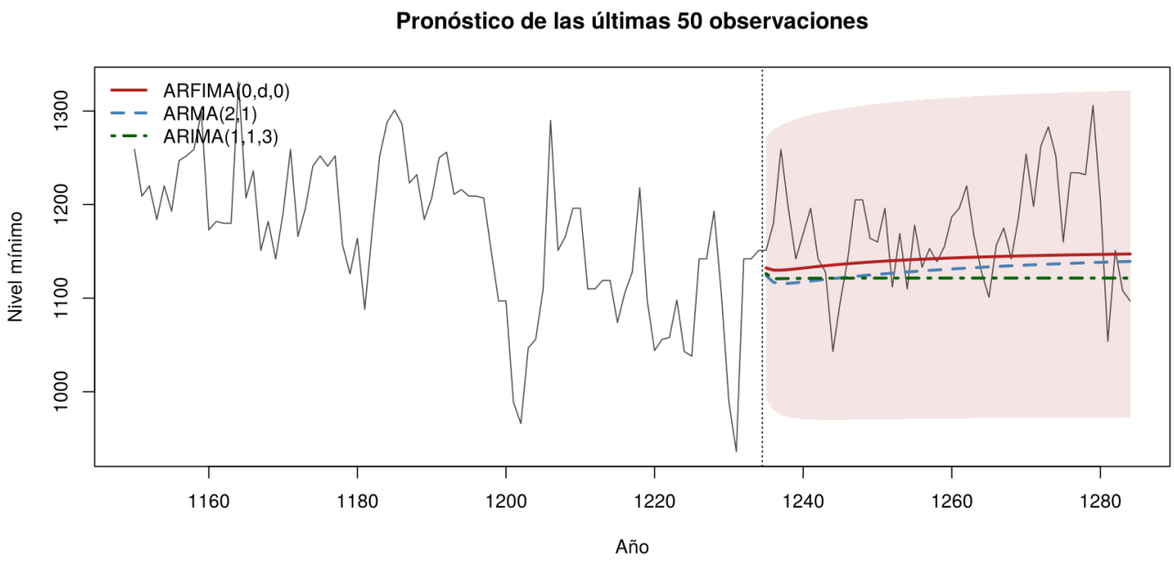


Figura 5: Pronóstico a varios pasos de las últimas 50 observaciones con los tres modelos. La franja sombreada es el intervalo de predicción del 95 % del ARFIMA$(0, d, 0)$.

9. CONCLUSIONES

Lo que decía la teoría y lo que encontramos

Todas las señales de memoria larga que describimos en el marco teórico aparecieron en la serie del Nilo. La ACF muestral bajó de forma lenta y se mantuvo significativa hasta cerca del rezago 75, en lugar de caer rápido como en un ARMA. El periodograma creció cerca de la frecuencia cero siguiendo casi una recta en escala log-log, que es justo la forma que predice la ecuación (3). Y las pruebas ADF y KPSS rechazaron al mismo tiempo, lo que muestra que la serie no encaja ni en el mundo de la memoria corta ni en el de la raíz unitaria, que son las dos únicas opciones que ofrecen los modelos vistos en el curso.

El parámetro de memoria estimado, $\hat{d} = 0.393$, quedó dentro del intervalo $(0, 0.5)$ con todo y su intervalo de confianza. Según la Tabla 1, eso significa que el Nilo es una serie estacionaria con memoria larga: no hace falta diferenciarla, pero tampoco se puede tratar como un ARMA. El

exponente de Hurst correspondiente, $\hat{H} = 0.89$, confirma con un modelo estadístico moderno el mismo efecto que Hurst describió hace más de setenta años estudiando este río.

También se cumplió lo que dijimos sobre los métodos de estimación. El estimador GPH dio valores entre 0.40 y 0.54 según cuántas frecuencias se usaran, así que es útil para detectar la memoria larga pero poco preciso para cuantificarla. La máxima verosimilitud, en cambio, dio valores de d muy parecidos (entre 0.35 y 0.39) sin importar la parte ARMA que se agregara al modelo.

Frente a los modelos del curso, el ARFIMA$(0, d, 0)$ describió la serie con un solo parámetro, mientras que el ARMA necesitó tres y el ARIMA cuatro para dejar residuales que también pasaran la prueba de Ljung-Box. En el pronóstico, el ARFIMA tuvo el menor error de los tres modelos tanto a un paso como a varios pasos, aunque a un paso la ventaja fue pequeña y a 50 años ninguno de los modelos le ganó a la media de la serie. Este último resultado nos parece importante: la memoria larga mejora el pronóstico frente a ARMA y ARIMA, pero no hace milagros a horizontes muy largos, donde cualquier modelo estacionario termina convergiendo a la media.

Ventajas de los modelos ARFIMA

- Llenan el vacío entre los ARMA ($d = 0$) y los ARIMA ($d = 1$). En lugar de escoger entre no diferenciar o diferenciar una vez, el modelo estima cuánto hay que diferenciar, y así evita la sobrediferenciación.
- Son parsimoniosos. Un solo parámetro, d, describe toda la dependencia de largo plazo, que un ARMA solo puede imitar con varios parámetros y con raíces muy cerca del círculo unitario.
- Separan los dos tipos de dependencia: d se encarga del largo plazo y la parte ARMA del corto plazo, y cada uno se puede interpretar por aparte.
- El parámetro d tiene una interpretación directa, tanto por sus rangos (Tabla 1) como por su relación con el exponente de Hurst.
- Sus pronósticos regresan a la media de forma gradual, lo que en nuestra aplicación se tradujo en menores errores que los de ARMA y ARIMA.

Desventajas de los modelos ARFIMA

- Son más difíciles de estimar. La verosimilitud exacta es costosa de calcular y en la práctica se usan aproximaciones. Además, encontramos que el error estándar de d que reporta el paquete `fracdiff` es poco confiable, y tuvimos que usar el error asintótico teórico.
- Los estimadores semiparamétricos, como el GPH, dependen mucho de decisiones arbitrarias como el número de frecuencias m.
- Necesitan series largas. Para distinguir la memoria larga de una memoria corta muy persistente hacen falta muchas observaciones; la serie del Nilo tiene 663, y no todas las series con las que se trabaja en la práctica son tan largas.
- Un cambio estructural en la media de una serie puede producir una ACF que decae lento y hacer que parezca tener memoria larga cuando en realidad no la tiene.
- Son menos conocidos y no vienen en herramientas de uso diario como `auto.arima`, así que requieren paquetes adicionales y más cuidado por parte del analista.

Comentario final

Los modelos ARFIMA no reemplazan a los ARMA y ARIMA, sino que los complementan. Cuando una serie muestra autocorrelaciones pequeñas pero muy persistentes, o cuando las pruebas de raíz unitaria y de estacionariedad se contradicen, vale la pena considerar un ARFIMA antes de forzar la serie en uno de los dos extremos que vimos en el curso. En el caso del Nilo, el modelo no solo ajustó mejor con menos parámetros, sino que permitió medir con un número el fenómeno que dio origen a toda esta teoría.

10. REFERENCIAS BIBLIOGRÁFICAS

Geweke, J. y Porter-Hudak, S. (1983). The estimation and application of long memory time series models. *Journal of Time Series Analysis*, 4(4), 221–238. `https://doi.org/10.1111/j.1467-9892.1983.tb00371.x`

Granger, C. W. J. y Joyeux, R. (1980). An introduction to long-memory time series models and fractional differencing. *Journal of Time Series Analysis*, 1(1), 15–29. `https://doi.org/10.1111/j.1467-9892.1980.tb00297.x`

Haslett, J. y Raftery, A. E. (1989). Space-time modelling with long-memory dependence: Assessing Ireland's wind power resource. *Applied Statistics*, 38(1), 1–50. https://doi.org/10.2307/2347679

Hosking, J. R. M. (1981). Fractional differencing. *Biometrika*, 68(1), 165–176. https://doi.org/10.1093/biomet/68.1.165

Hurst, H. E. (1951). Long-term storage capacity of reservoirs. *Transactions of the American Society of Civil Engineers*, 116, 770–808.

Maechler, M., Fraley, C., Hyndman, R., Leisch, F., Lemonte, A. y Reisen, V. (2026). *fracdiff: Fractionally Differenced ARIMA aka ARFIMA(P,d,q) Models* (versión 1.5-4) [Paquete de R]. https://doi.org/10.32614/CRAN.package.fracdiff

Shumway, R. H. y Stoffer, D. S. (2017). *Time Series Analysis and Its Applications: With R Examples* (4a ed.). Springer.

Toussoun, O. (1925). Mémoire sur l'histoire du Nil. *Mémoires de l'Institut d'Égypte*, 18, 366–404.